

Backpropagation Exercises

Forward and Backward Computational Graphs — Soluciones

Deep Learning

Antes de empezar, dejo aquí mi forma de trabajar cada ejercicio para que se entienda el hilo de todo el documento:

Primero escribo el modelo como una cadena de operaciones simples (sumas, multiplicaciones, funciones no lineales), porque así es literalmente como se calcula en la práctica y porque es la única forma de poder aplicar la regla de la cadena sin perderse. Luego calculo la pérdida, dibujo el grafo hacia adelante, y después voy "deshaciendo" el camino con la regla de la cadena, nodo por nodo, hasta llegar a cada parámetro. Al final dibujo el grafo hacia atrás con los gradientes escritos sobre las flechas, para que se vea de un vistazo por dónde fluye cada derivada.

$f(\mathbf{x}, \theta) \rightarrow$ salida del modelo $\ell = (f - y)^2 \rightarrow$ función de pérdida (error cuadrático)

Nota: en todos los ejercicios uso $\delta f = \partial \ell / \partial f = 2(f - y)$ para no repetir esa expresión cien veces; cuando la vean, es siempre esto.

Ejercicio 1: Modelo Lineal

Modelo:

$$\begin{aligned} f(\mathbf{x}, \theta) &= \omega \cdot \mathbf{x} + \beta \\ \theta &= \{\omega, \beta\} \end{aligned}$$

Solución

Este es el ejercicio más simple de toda la tanda, y por eso me sirve para fijar la mecánica que voy a repetir en los demás: cada operación (multiplicar, sumar, aplicar una función) se convierte en un nodo del grafo, y cada nodo tiene una entrada y una salida bien definidas.

1. Descomposición en operaciones elementales


Aquí solo hay dos pasos: multiplico ω por x , y al resultado le sumo β .

- $a = \omega \cdot x$
- $f = a + \beta$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward




4. Derivación backward (regla de la cadena)

Voy hacia atrás desde ℓ . Como $f = a + \beta$ es una suma, la derivada se reparte igual (multiplicada por 1) a ambos lados; por eso $\partial\ell/\partial a$ y $\partial\ell/\partial\beta$ terminan siendo exactamente lo mismo que $\partial\ell/\partial f$.

- $\partial\ell/\partial f = 2(f - y)$
- $\partial\ell/\partial a = \partial\ell/\partial f \cdot \partial f/\partial a = \partial\ell/\partial f \cdot 1 = 2(f - y)$
- $\partial\ell/\partial\beta = \partial\ell/\partial f \cdot \partial f/\partial\beta = \partial\ell/\partial f \cdot 1 = 2(f - y)$
- $\partial\ell/\partial\omega = \partial\ell/\partial a \cdot \partial a/\partial\omega = \partial\ell/\partial a \cdot x = 2(f - y) \cdot x$

Nota: el único paso donde aparece x es al derivar $a = \omega \cdot x$ respecto a ω , porque x hace de "escala" de esa multiplicación.

5. Grafo backward



6. Gradientes respecto a los parámetros

$$\partial\ell/\partial\omega = 2(f - y) \cdot x \quad \partial\ell/\partial\beta = 2(f - y)$$

Tiene sentido: si f está muy lejos de y (error grande) y además x es grande, el ajuste que le toca a ω también es grande. β , en cambio, no depende de x porque solo desplaza la recta.

Ejercicio 2: Una Activación No Lineal

Modelo:

$$f(\mathbf{x}, \theta) = \tanh(\omega \cdot \mathbf{x} + \beta)$$

$$\theta = \{\omega, \beta\}$$

Solución

Es exactamente el ejercicio anterior pero pasando el resultado por una tanh antes de llegar a la salida. Esto agrega un nodo extra en la cadena, así que el backward tiene un paso más.


1. Descomposición en operaciones elementales

- $z = \omega \cdot x + \beta$
- $f = \tanh(z)$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward




4. Derivación backward

La parte nueva respecto al ejercicio 1 es la derivada de la tanh: recordando que $d/dz[\tanh(z)] = 1 - \tanh^2(z)$, y como ya tenemos $f = \tanh(z)$ calculado del forward, podemos escribirlo directamente como $1 - f^2$, sin tener que recalcular nada.

- $\partial \ell / \partial f = 2(f - y)$
- $\partial \ell / \partial z = \partial \ell / \partial f \cdot \partial f / \partial z = \partial \ell / \partial f \cdot (1 - \tanh^2(z)) = 2(f - y)(1 - f^2)$ [pues $f = \tanh(z)$]
- $\partial \ell / \partial \omega = \partial \ell / \partial z \cdot \partial z / \partial \omega = \partial \ell / \partial z \cdot x$
- $\partial \ell / \partial \beta = \partial \ell / \partial z \cdot \partial z / \partial \beta = \partial \ell / \partial z \cdot 1$

Nota: esto es justo lo que hace útil guardar los valores intermedios durante el forward pass: reutilizamos f para no volver a calcular $\tanh(z)$ en el backward.

5. Grafo backward



6. Gradientes respecto a los parámetros

$$\partial \ell / \partial \omega = 2(f - y)(1 - f^2) \cdot x \quad \partial \ell / \partial \beta = 2(f - y)(1 - f^2)$$

Un detalle que vale la pena notar: el factor $(1 - f^2)$ se vuelve muy pequeño cuando f está cerca de 1 o -1 (la tanh se satura). Esto es justo el problema de "vanishing gradient" del que tanto se habla: si la neurona está saturada, casi no le llega gradiente y ω y β dejan de actualizarse.

Ejercicio 3: Una Neurona Oculta con Seno

Modelo:

$$f(x, \theta) = \omega_1 \cdot \sin(\omega_0 \cdot x + \beta_0) + \beta_1$$

$$\theta = \{\omega_0, \beta_0, \omega_1, \beta_1\}$$

Solución

Aquí ya tenemos una "neurona" completa con activación seno, seguida de una segunda transformación lineal (ω_1, β_1). Son 4 parámetros en dos capas, así que el backward tiene que atravesar dos multiplicaciones y una no linealidad.


1. Descomposición en operaciones elementales

- $z_0 = \omega_0 \cdot x + \beta_0$
- $s = \sin(z_0)$
- $a = \omega_1 \cdot s$
- $f = a + \beta_1$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward




4. Derivación backward

Voy bajando nodo por nodo. Lo único que cambia respecto a los ejercicios anteriores es la derivada del seno ($d/dz[\sin(z)] = \cos(z)$), que aparece cuando el gradiente cruza el nodo $s = \sin(z_0)$.

- $\partial \ell / \partial f = 2(f - y)$
- $\partial \ell / \partial a = \partial \ell / \partial f$ $\partial \ell / \partial \beta_1 = \partial \ell / \partial f$
- $\partial \ell / \partial \omega_1 = \partial \ell / \partial a \cdot s$
- $\partial \ell / \partial s = \partial \ell / \partial a \cdot \omega_1$
- $\partial \ell / \partial z_0 = \partial \ell / \partial s \cdot \cos(z_0)$
- $\partial \ell / \partial \omega_0 = \partial \ell / \partial z_0 \cdot x$ $\partial \ell / \partial \beta_0 = \partial \ell / \partial z_0$

5. Grafo backward



6. Gradientes respecto a los parámetros

$$\partial \ell / \partial \omega_1 = 2(f - y) \cdot \sin(z_0) \quad \partial \ell / \partial \beta_1 = 2(f - y)$$

$$\partial \ell / \partial \omega_0 = 2(f - y) \cdot \omega_1 \cdot \cos(z_0) \cdot x \quad \partial \ell / \partial \beta_0 = 2(f - y) \cdot \omega_1 \cdot \cos(z_0)$$

Se ve clarísimo el patrón de la regla de la cadena como "producto de eslabones": el gradiente que le llega a ω_0 es literalmente el producto de todo lo que atravesó en el camino ($2(f - y)$, luego ω_1 , luego $\cos(z_0)$, y finalmente x).

Ejercicio 4: MLP Escalar Profundo

Modelo:

$$f(x, \theta) = \omega_2 \cdot \tanh(\omega_1 \cdot \sin(\omega_0 \cdot x + \beta_0) + \beta_1) + \beta_2$$

$$\theta = \{\omega_0, \beta_0, \omega_1, \beta_1, \omega_2, \beta_2\}$$

Solución

Este es básicamente "apilar" el ejercicio 3 con una capa tanh encima. Son 6 parámetros y una cadena de 7 operaciones. No hay nada conceptualmente nuevo, pero sirve para practicar una cadena larga sin marearse: voy anotando en cada paso qué gradiente traigo "acumulado" desde la salida.


1. Descomposición en operaciones elementales

- $z_0 = \omega_0 \cdot x + \beta_0$
- $s = \sin(z_0)$
- $a_1 = \omega_1 \cdot s$
- $z_1 = a_1 + \beta_1$
- $t = \tanh(z_1)$
- $a_2 = \omega_2 \cdot t$
- $f = a_2 + \beta_2$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward




4. Derivación backward

Uso $\delta f = \partial \ell / \partial f$ para no arrastrar $2(f - y)$ en cada línea. La idea es simple aunque la cadena sea larga: en cada nodo multiplico por la derivada local de esa operación y sigo empujando el resultado hacia atrás.

- $\partial \ell / \partial f = 2(f - y)$ (denotamos $\delta f = \partial \ell / \partial f$)
- $\partial \ell / \partial a_2 = \delta f$ $\partial \ell / \partial \beta_2 = \delta f$
- $\partial \ell / \partial \omega_2 = \delta f \cdot t$ $\partial \ell / \partial t = \delta f \cdot \omega_2$
- $\partial \ell / \partial z_1 = \partial \ell / \partial t \cdot (1 - t^2)$
- $\partial \ell / \partial a_1 = \partial \ell / \partial z_1$ $\partial \ell / \partial \beta_1 = \partial \ell / \partial z_1$
- $\partial \ell / \partial \omega_1 = \partial \ell / \partial a_1 \cdot s$ $\partial \ell / \partial s = \partial \ell / \partial a_1 \cdot \omega_1$
- $\partial \ell / \partial z_0 = \partial \ell / \partial s \cdot \cos(z_0)$
- $\partial \ell / \partial \omega_0 = \partial \ell / \partial z_0 \cdot x$ $\partial \ell / \partial \beta_0 = \partial \ell / \partial z_0$

5. Grafo backward



6. Gradientes respecto a los parámetros (forma expandida)

$$\begin{aligned} \partial \ell / \partial \omega_2 &= \delta f \cdot t & \partial \ell / \partial \beta_2 &= \delta f \\ \partial \ell / \partial \omega_1 &= \delta f \cdot \omega_2 \cdot (1 - t^2) \cdot s & \partial \ell / \partial \beta_1 &= \delta f \cdot \omega_2 \cdot (1 - t^2) \\ \partial \ell / \partial \omega_0 &= \delta f \cdot \omega_2 \cdot (1 - t^2) \cdot \omega_1 \cdot \cos(z_0) \cdot x & \partial \ell / \partial \beta_0 &= \delta f \cdot \omega_2 \cdot (1 - t^2) \cdot \omega_1 \cdot \cos(z_0) \end{aligned}$$

Escrito así, expandido, se nota algo importante: entre más profunda es la red, más factores se van multiplicando en el gradiente de los parámetros de las primeras capas (ω_0, β_0). Si varios de esos factores son chicos (por ejemplo, $\tanh$ saturada), el producto se puede volver diminuto — otra vez el vanishing gradient, ahora en una red más profunda.

Ejercicio 5: Dos Neuronas Ocultas, Una Entrada

Modelo:

$$\begin{aligned} f(x, \theta) &= \omega_4 \cdot \tanh(\omega_0 \cdot x + \beta_0) + \omega_5 \cdot \sin(\omega_1 \cdot x + \beta_1) + \beta_2 \\ \theta &= \{\omega_0, \beta_0, \omega_1, \beta_1, \omega_4, \omega_5, \beta_2\} \end{aligned}$$

Solución

Este es el primer ejercicio con ramas: la misma entrada x alimenta a dos neuronas distintas (una con $\tanh$, otra con $\sin$), y sus salidas se suman al final. El enunciado ya lo advierte: cada rama se deriva por separado, y solo se "juntan" en el nodo de la suma.

1. Descomposición en operaciones elementales

Rama A (tanh):

- $z0 = \omega0 \cdot x + \beta0$
- $tA = \tanh(z0)$
- $a4 = \omega4 \cdot tA$

Rama B (seno):

- $z1 = \omega1 \cdot x + \beta1$
- $sB = \sin(z1)$
- $a5 = \omega5 \cdot sB$


Combinación:

- $\text{sum} = a4 + a5$
- $f = \text{sum} + \beta2$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward



4. Derivación backward

El truco de este ejercicio está en el nodo $\text{sum} = a4 + a5$. Como es una suma, cada rama recibe el gradiente completo de δf (no se reparte ni se divide entre dos, cada una recibe el mismo valor completo). A partir de ahí, cada rama se deriva exactamente igual que en los ejercicios 2 y 3, de forma totalmente independiente.

- $\partial \ell / \partial f = 2(f - y) = \delta f$
- $\partial \ell / \partial \text{sum} = \delta f \quad \partial \ell / \partial \beta2 = \delta f$
- Como $\text{sum} = a4 + a5$, el gradiente δf llega completo a cada rama: $\partial \ell / \partial a4 = \delta f$ y $\partial \ell / \partial a5 = \delta f$


Rama A:

- $\partial \ell / \partial \omega4 = \delta f \cdot tA \quad \partial \ell / \partial tA = \delta f \cdot \omega4$
- $\partial \ell / \partial z0 = \partial \ell / \partial tA \cdot (1 - tA^2)$
- $\partial \ell / \partial \omega0 = \partial \ell / \partial z0 \cdot x \quad \partial \ell / \partial \beta0 = \partial \ell / \partial z0$

Rama B:

- $\partial \ell / \partial \omega_5 = \delta f \cdot sB$ $\partial \ell / \partial sB = \delta f \cdot \omega_5$
- $\partial \ell / \partial z_1 = \partial \ell / \partial sB \cdot \cos(z_1)$
- $\partial \ell / \partial \omega_1 = \partial \ell / \partial z_1 \cdot x$ $\partial \ell / \partial \beta_1 = \partial \ell / \partial z_1$

5. Grafo backward



6. Gradientes respecto a los parámetros

$$\begin{aligned} \partial \ell / \partial \omega_4 &= \delta f \cdot tA & \partial \ell / \partial \omega_0 &= \delta f \cdot \omega_4 \cdot (1 - tA^2) \cdot x & \partial \ell / \partial \beta_0 &= \delta f \cdot \omega_4 \cdot (1 - tA^2) \\ \partial \ell / \partial \omega_5 &= \delta f \cdot sB & \partial \ell / \partial \omega_1 &= \delta f \cdot \omega_5 \cdot \cos(z_1) \cdot x & \partial \ell / \partial \beta_1 &= \delta f \cdot \omega_5 \cdot \cos(z_1) \\ \partial \ell / \partial \beta_2 &= \delta f \end{aligned}$$

Esto ya se parece bastante a lo que pasa dentro de una capa oculta real: varias neuronas compartiendo la misma entrada, cada una aprendiendo sus propios pesos, sin "pisarse" el gradiente entre ellas.

Ejercicio 6: MLP con Dos Entradas

Modelo:

$$\begin{aligned} \mathbf{x} &= (x_1, x_2) \\ f(\mathbf{x}, \theta) &= \omega_3 \cdot \tanh(\omega_0 \cdot x_1 + \omega_1 \cdot x_2 + \beta_0) + \beta_1 \\ \theta &= \{\omega_0, \omega_1, \beta_0, \omega_3, \beta_1\} \end{aligned}$$

Solución

Ahora el cambio es que la entrada ya no es un solo número sino un par (x_1, x_2) , cada uno con su propio peso. Para no complicarme, separo el producto $\omega_0 \cdot x_1$ y $\omega_1 \cdot x_2$ en dos nodos distintos (p_0 y p_1) antes de sumarlos; así queda clarísimo cómo se reparte el gradiente entre los dos pesos de entrada.


1. Descomposición en operaciones elementales

- $p_0 = \omega_0 \cdot x_1$
- $p_1 = \omega_1 \cdot x_2$
- $z_0 = p_0 + p_1 + \beta_0$
- $t = \tanh(z_0)$
- $a = \omega_3 \cdot t$
- $f = a + \beta_1$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward




4. Derivación backward

Lo importante aquí es notar que $z_0 = p_0 + p_1 + \beta_0$ es una suma de tres términos: como en toda suma, el mismo gradiente $\partial \ell / \partial z_0$ se copia (sin modificar) hacia cada uno de los tres sumandos. Recién después, al pasar de p_0 a ω_0 , aparece el factor x_1 (y análogamente x_2 para ω_1).

- $\partial \ell / \partial f = 2(f - y) = \delta f$
- $\partial \ell / \partial a = \delta f \quad \partial \ell / \partial \beta_1 = \delta f$
- $\partial \ell / \partial \omega_3 = \delta f \cdot t \quad \partial \ell / \partial t = \delta f \cdot \omega_3$
- $\partial \ell / \partial z_0 = \partial \ell / \partial t \cdot (1 - t^2)$
- Como $z_0 = p_0 + p_1 + \beta_0$ (suma), el gradiente se propaga íntegro a cada sumando:
- $\partial \ell / \partial p_0 = \partial \ell / \partial z_0 \quad \partial \ell / \partial p_1 = \partial \ell / \partial z_0 \quad \partial \ell / \partial \beta_0 = \partial \ell / \partial z_0$
- $\partial \ell / \partial \omega_0 = \partial \ell / \partial p_0 \cdot x_1 \quad \partial \ell / \partial \omega_1 = \partial \ell / \partial p_1 \cdot x_2$

5. Grafo backward



6. Gradientes respecto a los parámetros

Para no repetir la misma expresión tres veces, llamo g al gradiente que llega justo a z_0 :

$$g = \delta f \cdot \omega_3 \cdot (1 - t^2)$$

$$\partial \ell / \partial \omega_0 = g \cdot x_1 \quad \partial \ell / \partial \omega_1 = g \cdot x_2 \quad \partial \ell / \partial \beta_0 = g$$

$$\partial \ell / \partial \omega_3 = \delta f \cdot t \quad \partial \ell / \partial \beta_1 = \delta f$$

Ejercicio 7: MLP 2-2-1

Modelo:

$$\mathbf{x} = (x_1, x_2)$$

$$f(\mathbf{x}, \theta) = \omega_5 \cdot \tanh(\omega_0 \cdot x_1 + \omega_1 \cdot x_2 + \beta_0) + \omega_6 \cdot \text{ReLU}(\omega_2 \cdot x_1 + \omega_3 \cdot x_2 + \beta_1) + \beta_2$$

$$\theta = \{\omega_0, \omega_1, \beta_0, \omega_2, \omega_3, \beta_1, \omega_5, \omega_6, \beta_2\}$$

Solución

Esto ya es una mini red neuronal completa: dos entradas, dos neuronas ocultas (una con tanh y otra con ReLU) y una neurona de salida lineal. Es la combinación de las ideas de los ejercicios 5 y 6: dos ramas independientes (como en el 5) y cada rama con dos entradas ponderadas (como en el 6). La única pieza nueva es la derivada de ReLU.

1. Descomposición en operaciones elementales

Neurona oculta A (tanh):

- $z_A = \omega_0 \cdot x_1 + \omega_1 \cdot x_2 + \beta_0$
- $t_A = \tanh(z_A)$
- $a_A = \omega_5 \cdot t_A$

Neurona oculta B (ReLU):

- $z_B = \omega_2 \cdot x_1 + \omega_3 \cdot x_2 + \beta_1$
- $r_B = \text{ReLU}(z_B) = \max(0, z_B)$
- $a_B = \omega_6 \cdot r_B$


Capa de salida:

- $\text{sum} = a_A + a_B$
- $f = \text{sum} + \beta_2$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward



4. Derivación backward

Otra vez, $\text{sum} = a_A + a_B$ reparte el gradiente completo a las dos ramas. La rama A es idéntica en mecánica al ejercicio 6 (tanh con dos entradas). La rama B es la novedad: la derivada de ReLU es una función escalón, vale 1 donde $z_B > 0$ y vale 0 donde $z_B \leq 0$ (es decir, si la neurona ReLU estaba "apagada" en el forward, en el backward simplemente no deja pasar nada de gradiente por ahí).

- $\partial \ell / \partial f = 2(f - y) = \delta f$
- $\partial \ell / \partial \text{sum} = \delta f \quad \partial \ell / \partial \beta_2 = \delta f$
- $\partial \ell / \partial aA = \delta f \quad \partial \ell / \partial aB = \delta f$

Rama A (tanh):


- $\partial \ell / \partial \omega_5 = \delta f \cdot tA \quad \partial \ell / \partial tA = \delta f \cdot \omega_5$
- $\partial \ell / \partial zA = \partial \ell / \partial tA \cdot (1 - tA^2)$
- $\partial \ell / \partial \omega_0 = \partial \ell / \partial zA \cdot x_1 \quad \partial \ell / \partial \omega_1 = \partial \ell / \partial zA \cdot x_2 \quad \partial \ell / \partial \beta_0 = \partial \ell / \partial zA$

Rama B (ReLU):

- $\partial \ell / \partial \omega_6 = \delta f \cdot rB \quad \partial \ell / \partial rB = \delta f \cdot \omega_6$
- $\partial \ell / \partial zB = \partial \ell / \partial rB \cdot 1[zB > 0]$ (derivada de ReLU: 1 si $zB > 0$, 0 en caso contrario)
- $\partial \ell / \partial \omega_2 = \partial \ell / \partial zB \cdot x_1 \quad \partial \ell / \partial \omega_3 = \partial \ell / \partial zB \cdot x_2 \quad \partial \ell / \partial \beta_1 = \partial \ell / \partial zB$

Nota: si zB terminó siendo negativo en el forward, todo el bloque de gradientes de la rama B (ω_2 , ω_3 , β_1) sale en cero — es lo que se conoce como una neurona ReLU "muerta" para ese ejemplo puntual.

5. Grafo backward



6. Gradientes respecto a los parámetros

$$\begin{aligned} \partial \ell / \partial \omega_5 &= \delta f \cdot tA & \partial \ell / \partial \omega_0 &= \delta f \cdot \omega_5 \cdot (1 - tA^2) \cdot x_1 & \partial \ell / \partial \omega_1 &= \delta f \cdot \omega_5 \cdot (1 - tA^2) \cdot x_2 & \partial \ell / \partial \beta_0 &= \delta f \cdot \omega_5 \cdot (1 - tA^2) \\ \partial \ell / \partial \omega_6 &= \delta f \cdot rB & \partial \ell / \partial \omega_2 &= \delta f \cdot \omega_6 \cdot 1[zB > 0] \cdot x_1 & \partial \ell / \partial \omega_3 &= \delta f \cdot \omega_6 \cdot 1[zB > 0] \cdot x_2 & \partial \ell / \partial \beta_1 &= \delta f \cdot \omega_6 \cdot 1[zB > 0] \\ & & \partial \ell / \partial \beta_2 &= \delta f \end{aligned}$$

Ejercicio 8: Modelo Ramificado con Pre-activación Compartida

Modelo:

$$\begin{aligned} f(\mathbf{x}, \theta) &= \omega_3 \cdot \sin(\omega_0 \cdot \mathbf{x} + \beta_0) + \omega_4 \cdot \cos(\omega_0 \cdot \mathbf{x} + \beta_0) + \beta_1 \\ \theta &= \{\omega_0, \beta_0, \omega_3, \omega_4, \beta_1\} \end{aligned}$$

Solución

Este es, para mí, el ejercicio más interesante de toda la lista, porque rompe la idea de que "cada nodo tiene un solo camino de salida". Aquí $z_0 = \omega_0 \cdot \mathbf{x} + \beta_0$ se calcula una sola vez pero se usa dos veces: una para $\sin(z_0)$ y otra para $\cos(z_0)$. Eso significa que en el forward z_0 tiene dos flechas saliendo, y por lo tanto en el backward tiene que recibir dos flechas de gradiente entrando — y esas dos contribuciones no se promedian ni se eligen, se SUMAN. Esta es la regla general de backprop cuando un nodo se reutiliza: los gradientes de todos los caminos que salen de él se acumulan.


1. Descomposición en operaciones elementales

- $z0 = \omega0 \cdot x + \beta0$ (nodo compartido)
- $s = \sin(z0)$
- $c = \cos(z0)$
- $a3 = \omega3 \cdot s$
- $a4 = \omega4 \cdot c$
- $sum = a3 + a4$
- $f = sum + \beta1$

2. Pérdida

$$\ell = (f - y)^2$$

3. Grafo forward



4. Derivación backward

Hasta llegar a s y c , todo es igual que en los ejercicios anteriores (sum reparte δf completo a las dos ramas). Lo distinto empieza cuando quiero bajar de s y de c hacia $z0$: como $z0$ alimentó a ambos, tengo que calcular la contribución de cada camino por separado y después sumarlos.

- $\partial \ell / \partial f = 2(f - y) = \delta f$
- $\partial \ell / \partial sum = \delta f$ $\partial \ell / \partial \beta1 = \delta f$
- $\partial \ell / \partial a3 = \delta f$ $\partial \ell / \partial a4 = \delta f$
- $\partial \ell / \partial \omega3 = \delta f \cdot s$ $\partial \ell / \partial s = \delta f \cdot \omega3$
- $\partial \ell / \partial \omega4 = \delta f \cdot c$ $\partial \ell / \partial c = \delta f \cdot \omega4$

Acumulación de gradiente en $z0$ (nodo compartido):

- Contribución vía rama seno (recordando $d/dz[\sin(z)] = \cos(z)$): $\partial \ell / \partial z0 \mid_{\sin} = \partial \ell / \partial s \cdot \cos(z0) = \delta f \cdot \omega3 \cdot \cos(z0)$
- Contribución vía rama coseno (recordando $d/dz[\cos(z)] = -\sin(z)$): $\partial \ell / \partial z0 \mid_{\cos} = \partial \ell / \partial c \cdot (-\sin(z0)) = -\delta f \cdot \omega4 \cdot \sin(z0)$
- Como $z0$ tenía dos salidas, el gradiente total es la SUMA de ambas contribuciones (no se elige una ni se promedia, se suman tal cual):


$$\partial \ell / \partial z0 = \delta f \cdot \omega3 \cdot \cos(z0) - \delta f \cdot \omega4 \cdot \sin(z0) = \delta f \cdot [\omega3 \cdot \cos(z0) - \omega4 \cdot \sin(z0)]$$

- $\partial \ell / \partial \omega0 = \partial \ell / \partial z0 \cdot x$ $\partial \ell / \partial \beta0 = \partial \ell / \partial z0$

Nota: si en este ejercicio se me hubiera olvidado sumar y solo hubiera usado una de las dos ramas, el gradiente de $\omega0$ y $\beta0$ estaría mal y el modelo aprendería incorrectamente esos dos parámetros — por eso el enunciado insiste tanto en señalar este punto.

5. Grafo backward

En el dibujo se puede ver bien claro cómo dos flechas rojas (una desde s, otra desde c) llegan al mismo nodo z0 y ahí se combinan antes de seguir su camino hacia ω_0 y β_0 . Es la representación visual exacta de la acumulación de gradiente que acabo de describir arriba.



6. Gradientes respecto a los parámetros

$$\partial \ell / \partial \omega_3 = \delta f \cdot s \quad \partial \ell / \partial \omega_4 = \delta f \cdot c \quad \partial \ell / \partial \beta_1 = \delta f$$

$$\partial \ell / \partial \omega_0 = \delta f \cdot [\omega_3 \cdot \cos(z_0) - \omega_4 \cdot \sin(z_0)] \cdot x$$

$$\partial \ell / \partial \beta_0 = \delta f \cdot [\omega_3 \cdot \cos(z_0) - \omega_4 \cdot \sin(z_0)]$$

Cierro aquí la tanda de ejercicios. Si algo me llevo de resolverlos todos seguidos es que, por más que las fórmulas se vean cada vez más largas, en el fondo siempre es la misma receta: descomponer en pasos chiquitos, derivar cada paso por separado, y multiplicar/sumar las piezas en el orden correcto según el grafo. Las únicas reglas "nuevas" que aparecieron fueron: la suma reparte el gradiente igual a todos lados, y un nodo reusado acumula (suma) los gradientes de todos sus caminos de salida.